

大模型应用开发与 RAG 技术介绍

大语言模型简称 LLM，具备文本理解、内容生成、逻辑推理等能力，是目前人工智能应用开发的核心基础。

大模型应用开发实习岗位主要要求掌握 Python 编程、大模型 API 调用、Prompt 工程、RAG 检索增强生成技术。

RAG 全称检索增强生成，核心流程分为：文档加载、文本分段、向量化嵌入、向量数据库存储、相似度检索、大模型生成回答。

RAG 主要作用是解决大模型知识滞后、内容幻觉、无法使用私有本地文档的问题。

常用开发工具包括 LangChain 框架、Chroma 向量数据库、通义千问等大模型 API。

做 RAG 项目时需要对长文档进行切块拆分，设置合理的块大小和重叠量，提升检索准确率。

大模型实习必备技能：熟练 Python、会调用各大厂模型接口、理解 RAG 原理、能独立搭建简易知识库问答系统、会使用 Git 管理代码和 GitHub 托管项目。